



UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

Facultad de Ingeniería | Secretaría de Posgrado e Investigación
Programa Único de Especializaciones en Ingeniería

Modelación con Series de Tiempo del Nivel de Almacenamiento en el Sistema Cutzamala

EXAMEN GENERAL DE CONOCIMIENTOS

QUE PARA OPTAR POR EL GRADO DE:
Especialista en Hidráulica

PRESENTA:
Eduardo García Tapia

TUTORA:
M.I. Liliana Aguilar Yáñez

Resumen

Durante el primer semestre de 2024, los bajos niveles en las presas del Sistema Cutzamala han llevado a contemplar un posible día cero. El estudio selecciona y entrena un modelo de series de tiempo para realizar predicciones sobre la capacidad futura del Sistema para suministrar agua. Se utilizan datos del promedio trimestral de los registros diarios del volumen de almacenamiento en las presas El Bosque, Villa Victoria y Valle de Bravo, que conforman la infraestructura de almacenamiento del Sistema. El modelo resultante es producto de la optimización de los hiperparámetros de un proceso SARIMA multiplicativo. Se verificaron los supuestos necesarios sobre los residuales, para garantizar la significancia estadística de las predicciones realizadas para 2025 y 2026. Adicionalmente, se realizó una prueba de *backtesting* para validar el poder predictivo del modelo. A través de una construcción metódica, se logran evitar algunos sesgos encontrados en estudios previos, garantizando al mismo tiempo la calidad del modelo obtenido. Los resultados indican que continuarán las condiciones de escasez hídrica en el Sistema, por lo que la recuperación de los niveles en las presas que garantice el suministro futuro dependerá de lluvias extraordinarias y de la continuidad en las políticas de racionamiento.

Índice

1. Introducción	3
1.1. Cambio climático y seguridad hídrica.	3
1.2. El Sistema Cutzamala	4
1.3. Contexto y estructura de la investigación.	6
2. Datos utilizados	7
2.1. Obtención de lo datos	7
2.2. Análisis exploratorio de datos	11
2.3. Transformaciones	13
3. Modelación con series de tiempo	16
3.1. Marco teórico	16
3.2. Identificación del orden del modelo	18
3.3. Estimación de parámetros	22
3.4. Validación de supuestos	25
3.5. Optimización del modelo	28
4. Resultados y conclusiones	33
4.1. Validación de predicciones	33
4.2. Predicciones para 2025 y 2026	35
4.3. Conclusiones	36

1. Introducción

1.1. Cambio climático y seguridad hídrica.

El cambio climático es una realidad incuestionable; sus causas y efectos son plenamente observables y cuantificables. Es producto de los gases de efecto invernadero (GEI) que son emitidos a la atmósfera por las actividades humanas. En el último reporte del Panel Intergubernamental de Cambio Climático (IPCC, por sus siglas en inglés) (IPCC, 2021) se menciona que la temperatura promedio de la Tierra es actualmente entre 1.0°C y 1.5°C mayor a la registrada en el periodo preindustrial de 1850 a 1900.

Los impactos del cambio climático son irreversibles y progresivos, cualquier ruta de acción que tomen los gobiernos y ciudadanos para evitarlos será insuficiente; sus efectos, impactos y consecuencias moldearán una nueva etapa a la que la humanidad tendrá que adaptarse. En el año 2020 las emisiones anuales netas globales de dióxido de carbono (CO₂) fueron alrededor de 40 mil millones de toneladas. La mitigación del cambio climático consiste en reducir esta cifra neta, lo que implica tomar acciones orientadas a disminuir las emisiones o aumentar la absorción de CO₂ en la atmósfera. Sin embargo, apesar de que se alcance reducir esta cifra a la mitad para el año 2100, se espera que la temperatura media anual aumente entre 2.0°C y 3.0°C. Por lo tanto, la adaptación al cambio climático, que consiste en modificar las formas de producción, proteger a la sociedad frente a eventos climatológicos nunca antes observados, volver resiliente la infraestructura, entre otras acciones, es una tarea que debe empezar a tomarse en serio, pues será parte de la realidad para las generaciones actuales y futuras inmediatas.

Los nuevas condiciones climáticas no serán presentadas súbitamente. Los efectos del cambio pueden clasificarse como crónicos o agudos. Los crónicos son cambios graduales y persistentes que se desarrollan a lo largo de décadas o siglos. Por ejemplo, el aumento en el nivel medio del mar, que se estima en un metro para el año 2100, pero se espera que, debido los GEI actualmente existentes en la atmósfera, irreversiblemente en los próximos 10,000 años aumente en más de 10 metros. Los cambios agudos son eventos rápidos o extremos que se desarrollan durante días, meses o pocos años, como lo son los huracanes, inundaciones repentinas o sequías extremas. El aumento en frecuencia y severidad de los efectos crónicos y agudos no solo ponen en riesgo la vida humana, sino que tienen impactos directos en todos los sectores de la economía. Las nuevas condiciones climáticas ponen a prueba a las sociedades para poder desarrollarse de manera plena, integral y sostenible.

El agua es uno de los recursos que se espera que tengan mayor variabilidad en su disponibilidad, respecto a los patrones acostumbrados. Como elemento fundamental en la civilización es uno de los temas más importantes por atender. En la agenda 2030 definida por la ONU, uno de los objetivos de desarrollo sostenible (SDG, por sus siglas en inglés) es garantizar la disponibilidad y la gestión sostenible del agua y el saneamiento, con la finalidad de poner fin a la pobreza, proteger el planeta y mejorar las vidas y las perspectivas de las personas en todo el mundo.

El concepto de seguridad hídrica toma relevancia en un mundo que aspira a ser resiliente y sostenible. La seguridad hídrica se puede definir como la capacidad de la sociedad para

garantizar el agua en cantidad y calidad suficiente para que su población pueda cubrir sus necesidades humanas básicas (WRI, 2021). Una visión ampliada del concepto considera garantizar un equilibrio en los aspectos sociales, ambientales y económicos. El aspecto social implica que se haga un uso equitativo del recurso para toda la población, el ambiental busca garantizar la sostenibilidad, es decir, asegurar su disponibilidad para las generaciones futuras; y, el económico, maximizar los beneficios de su uso.

Una métrica que ayuda a medir el nivel de vulnerabilidad de la seguridad hídrica en un cierto lugar es el estrés hídrico. Es un indicador que agrega la disponibilidad de agua, la proyección de necesidades actuales y futuras, la calidad del agua y la disponibilidad de las fuentes de abastecimiento, que se resumen en la razón entre las extracciones totales de agua y las fuentes renovables superficiales y subterráneas (IMTA, 2022). De acuerdo con el Instituto de Recursos Mundiales (WRI, por sus siglas en inglés), México se encuentra en una posición poco favorable en esta materia, pues evalúa su riesgo por estrés hídrico como alto. A raíz de esto resulta imperativo que la seguridad hídrica sea un tema de importancia estratégica para el país.

La gestión de recursos hídricos nunca ha sido tarea fácil. La dinámica social, la urbanización desorganizada y el desarrollo industrial de zonas con poca disponibilidad hídrica, son los retos fundamentales que la ponen en riesgo. Encima de todo esto, el cambio climático llega para posicionarse como el reto más desafiante para el abastecimiento de agua en el mundo. Es requerida la construcción de infraestructura resiliente, así como la modificación de la existente, con el fin de garantizar la adaptación a la nueva realidad.

Uno de los grandes avances en la mitigación y adaptación al cambio climático es que la comunidad científica, el sector privado, los gobiernos y la sociedad civil lo aceptan como una realidad y se entiende la urgencia de su atención. Es esencial que todos los actores colaboren para implementar soluciones que ayuden a conseguir un mundo sostenible y la estabilidad climática. Las soluciones tecnológicas novedosas y la conciencia de la sociedad son habilitadores para que los creadores de políticas públicas tomen las acciones necesarias para combatir el que es el mayor reto al que la humanidad se ha enfrentado.

1.2. El Sistema Cutzamala

El Sistema Cutzamala es el conjunto de infraestructura para el abastecimiento de agua más importante de México. Su principal función es proveer de agua potable a la Zona Metropolitana del Valle de México (ZMVM), por lo que resulta fundamental para satisfacer las necesidades hídricas de millones de mexicanos.

El agua disponible dentro de los límites geográficos de la ZMVM no es suficiente para satisfacer sus necesidades. Históricamente la Ciudad de México se abastecía de agua a través de extracciones de pozos en sitio. A mediados del siglo XX el incremento en la demanda hídrica fue atendido con la construcción del Sistema Lerma, el cual consiste de una serie de pozos cuyas extracciones después son encausadas dentro de la Ciudad, con lo que se marca el precedente de que es viable trasvasar aguas de otras cuencas para completar el suministro de agua dentro de la ZMVM.

Debido a la imposibilidad de satisfacer la demanda de agua, los hundimientos provocados

por la sobreexplotación del acuífero y la proyección de la demanda futura, en la década de los 70's se ideó el Sistema Cutzamala, que inicio su operación en 1982 ([CONAGUA, 2005](#)), aprovechando el almacenamiento en la presa Villa Victoria en el Estado de México, la cual originalmente se utilizaba para la generación de energía eléctrica.

A través de las 3 etapas que han marcado su construcción, la última concluyendo en el año de 1993 ([Juan D., 2021](#)), el Sistema Cutzamala ha surtido a la Ciudad de México en promedio 15,000 litros por segundo de agua potable, lo cual representa el 23.9 % del suministro, además de las extracciones locales de pozos (68.2 %) y el Sistema Lerma (7.9 %) ([Banco Mundial, 2015](#)). Su relevancia estratégica en la ZMVM es inegable, pues en total son abastecidos 14 municipios del Estado de México y 13 alcaldías de la Ciudad de México.

En la actualidad el Sistema Cutzamala es un sistema hídrico de producción, almacenamiento, conducción, potabilización y distribución. Está conformado por 4 presas derivadoras: Tuxpan (Michoacán), Colorines (Estado de México), Ixtapan del Oro (Edo. Mex.) y Chilesdo (Estado de México); por 3 presas almacenadoras: El Bosque (Michoacán), Villa Victoria (Edo. Mex.) y Valle de Bravo (Edo. Mex.); 6 plantas de bombeo, con 1,000 metros de altura a vencer entre el punto más bajo y el más alto; 1 planta potabilizadora con capacidad de 20 m^3/s y más de 300 kilómetros en conducción que incluyen tramos de tubería, canales y túneles.

Para garantizar la operación sostenible del Sistema se deben considerar cuestiones tecnológicas, sociales y ambientales. Entre las tecnológicas se encuentran los costos de operación y mantenimiento, la actualización y sustitución de los equipos, el desgaste de las instalaciones y el nivel de azolve de las presas.

Dentro de los retos sociales se encuentra la atención a la población abastecida, las cuales son las que resienten la variabilidad en su operación, la consideración a comunidades vecinas, pues existe un sentimiento de allanación de sus recursos, la industria turística que existe alrededor de los embalses, pues son el eje económico de algunas localidades, como es el caso de Valle de Bravo.

Finalmente, los retos ambientales tienen una complejidad añadida debido al cambio climático. Entre éstos se encuentran la creciente variabilidad de los patrones de precipitación, el aumento en la temperatura que favorezca la evaporación y la modificación de vegetación en la cuenca debida al cambio de uso de suelo.

En los últimos meses la disminución en los niveles de almacenamiento en las presas del Sistema Cutzamala ha sido tan fuerte, que se han alcanzado niveles mínimos históricos. Algunos de los motivantes de esta situación son la sequía hidrológica, malas políticas de operación de las presas y tomas clandestinas. Para garantizar un suministro continuo se han adoptado políticas de operación de las presas más estrictas, lo que se refleja en recortes al suministro. Al ser la población la principal afectada por estos cambios, los temas de la disponibilidad hídrica en el Sistema Cutzamala y cuidado del agua han tomado un papel relevante en la opinión pública.

El Sistema Cutzamala es vital para el desarrollo social y económico en toda la ZMVM, pensar en un escenario de día cero es catastrófico. Como consecuencias del cambio climáti-

co no se espera que la precipitación media anual cambie sustancialmente, pero sí se proyecta que serán más extremas las temporadas de exceso y carencia de lluvia, por lo que se vuelve relevante prever las sequías y administrar adecuadamente los recursos hídricos.

1.3. Contexto y estructura de la investigación.

El agua como un recurso esencial para el desarrollo social y económico debe garantizarse en su disponibilidad y calidad. Los recortes en el suministro del Sistema Cutzamala, debido a que el nivel de almacenamiento en las presas se encuentra en mínimos históricos, han hecho que se vuelva un foco de discusión pública durante los últimos años. Junto con la creciente conciencia sobre el cuidado del medio ambiente y las consecuencias del cambio climático, se ha vuelto palpable la posible llegada de un día cero, en el cual no sea posible surtir agua potable debido a su agotamiento en la fuente de abastecimiento.

Los ciudadanos son los más vulnerables frente a los recortes en el suministro, pero no solo ellos son afectados, sino que también son perturbadas las actividades agrícolas, industriales y empresariales. El manejo de los recursos hídricos es un tema que no concierne únicamente a los ciudadanos, pues dentro del ámbito político se ha vuelto una de las métricas con la cual los gobiernos son evaluados en la calidad de su gestión, por su influencia en todos los aspectos de la vida nacional.

Es sabido que la lluvia es un proceso estocástico (aleatorio) que no puede determinarse con precisión. Esto representa un riesgo en la seguridad hídrica, ya al nunca tener certeza sobre el agua disponible en el futuro, por lo que la planeación se hace en un ambiente de incertidumbre. Ante este tipo de escenarios las técnicas estadísticas proporcionan una solución adecuada, pues en vez de buscar una respuesta única determinística, se trabaja con probabilidades e intervalos de confianza que dan certidumbre en un entorno incierto.

La hipótesis central del trabajo es que empleando un modelo de series de tiempo es posible reproducir el comportamiento estocástico que existe en el cambio del nivel de almacenamiento de agua en las presas del Sistema Cutzamala, considerando las tres presas almacenadoras como un conjunto y medido en una escala del 0 % al 100 %. También se espera que las predicciones realizadas con el modelo no solo permitan vislumbrar el futuro cercano, sino que en múltiples pasos de tiempo adelante.

El objetivo general es mostrar la validez y utilidad que tienen los modelos de series de tiempo para predecir el complejo comportamiento de un sistema de presas, considerando como un conjunto el proceso estocástico de la lluvia, la influencia humana en las políticas de operación, la evaporación en los embalses, las extracciones ilegales, las infiltraciones al subsuelo, etc, con lo que se logra simplificar el método de cálculo de dichos niveles frente a un modelo determinístico.

En el capítulo siguiente se presentan los datos utilizados, de donde son obtenidos, que representan y cómo son modificados para su modelación. Después se desarrolla el proceso de construcción del modelo de series de tiempo, desde la identificación de la forma de éste, la estimación de los parámetros y la optimización para maximizar su poder predictivo. Al final son presentadas las predicciones obtenidas y se exponen las conclusiones.

2. Datos utilizados

2.1. Obtención de lo datos

La información histórica utilizada es obtenida directamente de la Comisión Nacional del Agua (CONAGUA), organismo encargado de la gestión administrativa de los recursos hídricos del país, a través de la Subdirección General Técnica. A su vez, el Organismo de Cuenca Aguas del Valle de México (OCAVAM) es la dependencia específica encargada de la operación y monitoreo del nivel de almacenamiento en las presas en el Sistema Cutzamala. Los datos fueron obtenidos a través del Sistema de Información Hidrológica (SIH) en su portal de internet <https://sih.conagua.gob.mx/>. La fecha de consulta fue el 1° de agosto de 2024, todos los archivos requeridos se encontraban disponibles.

Se descargó un archivo CSV con datos históricos diarios del almacenamiento para cada una de las presas que conforman el almacenamiento del Sistema: Villa Victoria, El Bosque y Valle de Bravo. El formato de los archivos es estandarizado y en todos se encuentran los mismos campos, aunque no para todos se tiene la información completa. En la [Tabla 1](#) se listan los campos disponibles para las 3 presas:

Campo	Descripción
Fecha	Identificador del día para el cual se proporcionan la información.
Elevación	Altura en msnm del espejo del agua en el embalse de la presa.
Almacenamiento	Volumen en hectómetros cúbicos de agua almacenada, calculada a partir de la curva de elevaciones-capacidades del embalse.
Área	Área en hectáreas cuadradas que abarca el espejo de agua, calculado a partir de la curva elevaciones-área del embalse de la presa.
Extracciones por obra de toma	Volumen extraído para su aprovechamiento en el Sistema o como medida de gasto ecológico aguas abajo del embalse.
Extracciones por vertedor	Volumen excedente desalojado por propósitos de seguridad. Este volumen no es aprovechable.
Evaporación	Medida tomada fuera del embalse que representa la evaporación en el sitio.
Precipitación	Medida tomada fuera del embalse que representa la lámina de precipitación en el sitio.

Tabla 1: Descripción de los campos en los archivos descargados del SIH

Las presas de interés son las almacenadoras: Villa Victoria, Valle de Bravo y el Bosque. El Sistema se compone de 6 presas en total, pero las restantes son derivadoras (o sea que no tienen un reservorio), por lo que para el objetivo del estudio no son relevantes.

En la [Figura 1](#) se muestra la ubicación de las presas, su área de captación y el tipo. En territorio de captación de escurrimientos del Sistema Cutzamala es de un total de 3,400 km², lo que equivale alrededor de 2.3 veces el territorio de la Ciudad de México.




Figura 1: Cuencas de captación del Sistema Cutzamala

Los campos de interés son: *Fecha* y *Almacenamiento*. En un primer vistazo de la información disponible se observa una buena cobertura de información. La ventana de tiempo del estudio comienza a partir de 1994, año en el que por primera vez se cuenta con el sistema de presas operando como un conjunto y abasteciendo al Cutzamala, con la misma configuración que en la actualidad. El final del periodo de análisis es Julio 2024. En la [Tabla 2](#) se muestra un resumen de la disponibilidad de información.

Presa	Periodo de cobertura	Datos faltantes
Villa Victoria	Enero 1994 a julio 2024	0
Valle de Bravo	Enero 1994 a julio 2024	44
El Bosque	Enero 1994 a julio 2024	0

Tabla 2: Datos disponibles.

Los datos faltantes fueron imputados con una interpolación lineal entre el registro pasado y el futuro más próximos. No se esperan que altere el resultado del análisis significativamente, pues los datos faltantes representan apenas el 0.40 % de la serie de tiempo para la presa Valle de Bravo y la secuencia más larga de datos faltantes es de apenas 16 días.

Los datos se presentan de forma diaria, pero para fines del estudio estos son agrupados anualmente por temporadas. Las cuatro temporadas definidas son DEF: Diciembre, Enero y Febrero; MAM: Marzo, Abril y Mayo; JJA: Junio, Julio y Agosto; y SON: Septiembre,

Octubre y Noviembre. Se genera una nueva observación agregada al promediar los almacenamientos diarios, en la [Ecuacion 1](#) se muestra la notación. El periodo de cobertura de datos comienza en Enero, para la primera observación "1994 - DEF" solo se consideran 58 registros, correspondientes a Enero y Febrero, en vez de los 90 días en los tres meses. Se define una serie de tiempo para cada presa, en la notación se especifica con el superíndice. En total se tienen 123 observaciones, 4 por año para 30 años y las primeras 3 del 2024 hasta Junio, Julio y Agosto.

$$A_i^{VV}, A_i^{VB}, A_i^{BO} \quad ; \quad i \in (1, 2, \dots, k) \quad ; \quad k = 123 \quad (1)$$

En la [Figura 2](#) se muestra el comportamiento histórico del almacenamiento en cada una de las presas. La más afectada por la sequía es Valle de Bravo, pues se encuentra en un mínimo histórico. La tendencia descendiente comienza en el año 2020, pues no existió una recuperación de la época de estiaje anterior, seguido de un periodo de extracción importante. La presa Villa Victoria también presenta un nivel equiparable con el mínimo histórico, que ya había ocurrido en el 2010. El almacenamiento en El Bosque está en un nivel menos crítico, sin embargo se observan los efectos de la sequía hidrológica, pues no fue tanta la recuperación en la última temporada de lluvias.




Figura 2: Series de tiempo del almacenamiento en cada presa

Una consideración especial que se debe de tener es la de distinguir entre los niveles de operación de las presas y el nivel de almacenamiento aprovechable de éstas. Los niveles de azolve y la altura a la que se encuentran las obras de toma son el motivo. Hacer omisión de esta distinción tiene como resultado que se sobreestime el porcentaje de almacenamiento. En la [Tabla 3](#) se expresan las capacidades de almacenamiento en el Namino y Namo.

El Namino (nivel de aguas mínimo de operación) es el nivel del espejo y carga del agua para el cual las obras de toma pueden funcionar de manera segura, de lo contrario se

podría presentar el arrastre de azolves o la mezcla de agua con aire en el flujo que alimenta los equipos de bombeo, provocando daños en los álabes o equipo electromecánico. Por su parte, el Namó (nivel de aguas máximo de operación) también representa un límite operacional para la infraestructura, sobrepasarlo pone en riesgo la integridad de la cortina y el funcionamiento correcto de los equipos que reciben el afluente.

Presa	Namino	Namo	Volumen útil	Porcentaje aprovechable
	millones de m³			
Villa Victoria	30.0	185.73	155.73	83.84 %
Valle de Bravo	50.0	394.39	344.39	87.32 %
El Bosque	60.0	202.40	142.40	70.35 %
Total	140.0	782.52	642.52	82.11 %

Tabla 3: Capacidades de almacenamiento. Fuente: (Juan D., 2021)

El Sistema Cutzamala se trabaja como un conjunto, por lo que el almacenamiento de las presas es acumulado, como se especifica en la Ecuación 3, cuyo comportamiento histórico se muestra en la Figura 3. La necesidad de un superfiijo es eliminada, dando por entendido que en la ausencia de éste se trata del almacenamiento total en las 3 presas.

$$A_i = A_i^{VV} + A_i^{VB} + A_i^{BO} \quad (2)$$




Figura 3: Serie de tiempo del almacenamiento en el Sistema Cutzamala

2.2. Análisis exploratorio de datos

El análisis exploratorio de datos es un proceso esencial para la modelación estadística. Permite entender la naturaleza de los datos, resolver dudas sobre su comportamiento, detectar puntos de interés, formular preguntas significativas sobre éstos y establecer los objetivos de la modelación. En este apartado se muestran tres visualizaciones orientadas a tener una mayor comprensión de la crisis hídrica por la que atraviesa el Sistema.

La primera visualización es una serie de tiempo de medias móviles con una ventana de 8 temporadas, es decir, el promedio de almacenamiento en los 2 años previos; se muestra en la [Figura 4](#). Se aprende que el almacenamiento es fluctuante, existen temporadas de déficit que eventualmente son superadas. Uno de los mensajes más importantes es que la temporada de bajo almacenamiento que se está viviendo en la actualidad es, en realidad, la crisis más importante por la que haya atravesado el Sistema.




Figura 4: Media móvil de 8 periodos del almacenamiento en el Sistema

En la [Figura 5](#) se observan a detalle los últimos 9 años, con el cambio en el almacenamiento a un tiempo. La temporada de Septiembre, Octubre y Noviembre es en la que ocurre anualmente la recuperación de los niveles, pero ha existido un desbalance que provoca que paulatinamente disminuya el almacenamiento. A excepción de 2021, desde 2019 se han presentado temporadas de lluvias especialmente bajas que no logran amortiguar la tendencia descendiente.

Por último, en la [Figura 6](#) se muestra la dispersión histórica por temporada de los niveles medios de almacenamiento. Se observa que el año se divide en temporadas de alto y bajo almacenamiento, que se generan por los patrones de precipitación en la región. El mínimo histórico se alcanzó para cada una de las temporadas pasadas. Para la temporada de Junio, Julio y Agosto, el segundo registro más bajo es 2023, el año inmediato anterior.




Figura 5: Diferencia de una temporada en el almacenamiento




Figura 6: Diagrama de cajas del almacenamiento por temporada

2.3. Transformaciones

Las transformaciones en estadística son herramientas esenciales para modificar y adaptar datos, de manera que cumplan con ciertos supuestos necesarios en la aplicación de modelos. La búsqueda de normalidad en los datos o los residuales, tras el ajuste del modelo, es una de las metas más comunes que se persiguen al aplicar transformaciones. Para este trabajo no es la excepción, ya que la teoría de series de tiempo que se emplea en los capítulos siguientes se desarrolla a partir de estos supuestos de normalidad.

Aplicar transformaciones arbitrariamente a los datos no representa por sí mismo una limitante o una posible fuente de error. Las salvaguardas más importantes que se deben de tener son que las transformaciones aplicadas realmente tengan un resultado benéfico para el análisis posterior y que todas tengan inversa, para poder llevar de regreso los datos a su espacio original, en el cual se pueden obtener conclusiones relevantes.

Como primer transformación se obtienen los porcentajes de almacenamiento efectivo (P_t), que consideran el rango entre el Namoy y el Namino. En la [Ecuacion 3](#) se muestra el cálculo a partir de A_t , que denota la serie de tiempo del almacenamiento medio por temporada. En la [Figura 7](#) se observa la serie de tiempo transformada.

$$P_t = \frac{A_t - Namino}{Namoy - Namino} \quad ; \quad A_t \in [0, Namoy] ; P_t \in [0, 1] \quad (3)$$




Figura 7: Serie de tiempo del porcentaje aprovechable.

Note que P_t sigue sin ser adecuada para la modelación, pues los procesos estocásticos no están acotadas al dominio resultante, sino que pueden tomar valores en todos los números

reales. En la [Ecuacion 4](#) se muestra la segunda transformación realizada, con la que se tiene la nueva serie M_t . Se toma como base el cálculo de los momios) en una distribución binomial, aprovechando que el porcentaje calculado en el paso anterior tiene su dominio acotado entre 0 y 1. En la [Figura 8](#) se observa la serie de tiempo transformada.

$$M_t = \frac{P_t}{1 - P_t} \quad ; \quad M_t \in (0, \infty) \quad (4)$$




Figura 8: Serie de tiempo con los momios del porcentaje aprovechable

La última transformación, con el fin de estabilizar la varianza a lo largo del tiempo y de esta manera atender con antelación el problema de falta de normalidad en los residuales e intentar reducir el sesgo en la distribución de las observaciones, se aplica una transformación Box Cox. En la [Ecuacion 5](#) se muestra el cómputo de ésta.

$$X_t(\lambda) = \begin{cases} \frac{M_t^\lambda - 1}{\lambda} & ; \quad \lambda \neq 0 \\ \ln(M_t) & ; \quad \lambda = 0 \end{cases} \quad (5)$$

Utilizando R, la librería *forecast* y la función *BoxCox.lambda()* se obtiene el valor óptimo $\lambda = -0.239935$, al minimizar el coeficiente de variación de la serie, método propuesto por [\(Guerrero, 1993\)](#). En consecuencia, la forma final de la transformación es como se muestra en la [Ecuacion 6](#).

$$X_t = \frac{M_t^{-0.239935} - 1}{-0.239935} \quad ; \quad X_t \in (-\infty, -0.239935^{-1}) \quad (6)$$

El dominio de X_t es resultado de elevar la serie M_t a la λ potencia, pues para garantizar la invertibilidad de la transformación se necesita un argumento de la raíz cero o estrictamente positivo. Por ende, cualquier valor simulado en la serie de tiempo que sea mayor a $-\lambda^{-1} = 0.239935^{-1} = 4.167793$, implicaría que el análisis no es válido y que todas las conclusiones a las que se lleguen no serían representativas del fenómeno en estudio. Este límite es natural al fenómeno de estudio, pues representa el momio de valor 0, que a su vez describe el porcentaje de almacenamiento de 0 %.

En los pasos subsecuentes se tiene esta consideración en mente y se hacen las validaciones necesarias para garantizar que los resultados se encuentren en el dominio de invertibilidad. La transformación Box Cox es una herramienta muy útil, pues al estabilizar la varianza se espera que al ajustar un modelo de series de tiempo sea extremadamente baja la probabilidad de alcanzar la cota de no-invertibilidad.

Se observa en la [Figura 9](#) la serie final, a la que se le ajustará un modelo de series de tiempo. A primera vista parece que X_t se asemeja bastante en su forma a la serie original A_t . Esto podría poner en duda la utilidad y el objeto de las transformaciones realizadas, sin embargo, debe notarse que la serie transformada tiene propiedades distintas en la varianza y en su dominio, pues a pesar de estar acotada superiormente, la expectativa es favorable para poder ajustar un modelo.




Figura 9: Serie de tiempo de los momios transformada con Box Cox

3. Modelación con series de tiempo

3.1. Marco teórico

Una serie de tiempo es una colección de observaciones estocásticas indexadas en el tiempo $\{X_t\}$. Para generar predicciones sobre ellas la teoría estocástica de series de tiempo es la indicada. Elegir la forma del proceso y el orden del modelo a ajustar es la tarea más importante que tiene el modelador. Los cálculos y cuestiones técnicas están facilitadas en la actualidad, gracias a la popularidad y utilidad de este tipo de modelo existe una gran variedad de librerías en diferentes lenguajes de programación.

El objetivo primordial de este subcapítulo es presentar de manera general los procesos utilizados para la modelación y tener un marco teórico que respalde los cálculos realizados. Queda fuera del alcance el desarrollar sobre la teoría de series de tiempo y las cuestiones matemáticas detrás de ella. Se consultaron algunos libros especializados y se homologa lo descrito en cada uno de ellos. Se utiliza R como la paquetería estadística utilizada para todos los cálculos presentados.

En este trabajo se emplea un modelo multiplicativo SARIMA $(p,d,q) \times (P,D,Q)_S$ (por las siglas en inglés de sus componentes, *Seasonal Autorregressive Integrated Moving Average*). Los modelos SARIMA multiplicativos ofrecen la posibilidad de ajustar simultáneamente un modelo para la componente no estacional, utilizando de un modelo ARMA(p, q); y otro para la estacional, utilizando de un modelo ARMA(P, Q). También permite trabajar con procesos no estacionarios al incorporar la diferenciación en d tiempos para la componente no estacional y D tiempos para la estacional.

Establecer el orden de los modelos (p, d, q, P, D, Q) permite que los procesos SARIMA sean muy flexibles y adecuados para la modelación, ya que se pueden ajustar modelos AR(p), MA(q), etc., al fijar como cero el resto de las componentes. Esta característica es por la cual se eligió este proceso, pues abarca otro tipo de modelos.

De (Brockwell & Davis, 2016) se rescata la siguiente definición. Si d y D son enteros no negativos, entonces $\{X_t\}$ es un proceso SARIMA $(p, d, q) \times (P, D, Q)_S$ con periodo S si la serie diferenciada $Y_t = (1 - B)^d(1 - B^S)^D X_t$ es un proceso ARMA definido por:

$$\phi(B)\Phi(B^S)Y_t = \theta(B)\Theta(B^S)\epsilon_t \quad (7)$$

donde:

$$\{\epsilon_t\} \sim \text{Ruido Blanco}(0, \sigma^2)$$

El proceso estocástico de Ruido Blanco es un proceso Gaussiano. Básicamente se podría definir como la generación aleatoria de observaciones a partir de una distribución normal con media cero y varianza constante para todo t , con la restricción de que las observaciones son independientes. El suponer la forma de $\{\epsilon_t\}$ toma mucha importancia en la fase final de la modelación, pues la validación del proceso ajustado se hace a través de la revisión de normalidad e independencia de los residuales del modelo.

El material presentado por (Salas, 1980) es muy relevante para el estudio de series hidrológicas mediante series de tiempo, provee un puente sólido entre la ingeniería civil y las matemáticas. Tanto así que fue el punto de partida para realizar este trabajo. Con la

finalidad de homologar notaciones y hacer un vínculo entre la literatura especializada y la aplicada, del mismo libro se toman las siguientes definiciones, adaptando la notación para que coincida con la expresada en la [Ecuacion 7](#) y que sirva para el resto de la teoría que se explica posteriormente.

Operador de retraso (B):	$Bx_t = x_{t-1}$
Primera diferencia:	$(1 - B)x_t = x_t - x_{t-1}$
Segunda diferencia:	$(1 - B)^2x_t = (1 - B)(1 - B)x_t = x_t - 2x_{t-1} + x_{t-2}$
Primera diferencia estacional:	$(1 - B^S)x_t = x_t - x_{t-S}$
Segunda diferencia estacional:	$(1 - B^S)^2x_t = x_t - 2x_{t-S} + x_{t-2S}$
Operador autorregresivo:	$\phi(B) = (1 - \phi_1B - \phi_2B^2 - \dots - \phi_pB^p)$
Operador de medias móviles:	$\theta(B) = (1 - \theta_1B - \theta_2B^2 - \dots - \theta_qB^q)$
Operador estacional autorregresivo:	$\Phi(B^S) = (1 - \Phi_1B^S - \Phi_2B^{2S} - \dots - \Phi_PB^{PS})$
Operador estacional de medias móviles:	$\Theta(B) = (1 - \Theta_1B - \Theta_2B^2 - \dots - \Theta_QB^Q)$

Una restricción importante que se hace a los modelos SARIMA es garantizar la estacionariedad, invertibilidad y causalidad del modelo ARMA subyacente, tanto para la componente ordinaria como para la estacional. En ([Huang & Pethukina, 2022](#)) se detalla que se aseguran estas características sí y solo sí las raíces de los polinomios generados por los operadores autorregresivos y de medias móviles se encuentren fuera del círculo unitario. En otras palabras, la inversa de éstos están dentro.

Para ilustrar el punto anterior se reescribe como en la [Ecuacion 8](#).

$$\phi^*(B)Y_t = \theta^*(B)\epsilon_t \quad (8)$$

donde $\phi^*(B) = \phi(B)\Phi(B^S)$, es un polinomio de orden $p + SP$ y $\theta^*(B) = \theta(B)\Theta(B^S)$ es un polinomio de orden $q + SQ$. Debido a cuestiones de análisis funcional cuya explicación queda fuera del alcance de este trabajo, los operadores autorregresivos y de medias móviles pueden considerarse como polinomios algebraicos con forma $\phi^*(z)$ y $\theta^*(z)$. Debido a esto, las características de estacionariedad, causalidad e invertibilidad del modelo ajustado son garantizadas si todas las raíces de los polinomios característicos yacen fuera del círculo unitario. Es decir que $\phi^*(z) = 0$ y $\theta^*(z) = 0$ para $|z| > 1$.

3.2. Identificación del orden del modelo

Las funciones de autocorrelación (ACF) y de autocorrelación parcial (PACF) están bien definidas y son conocidas en su forma para los procesos $AR(p)$ y $MA(q)$, por lo que un análisis de los autocorrelogramas muestrales sugieren la elección del orden de alguno de estos modelos. En el caso de modelos $ARMA(p, q)$, la función de autocorrelación extendida (EACF) es útil para identificar el orden conjunto; sin embargo esta tarea usualmente es poco práctica por las variaciones muestrales.

La identificación de modelos multiplicativos SARIMA, como el que se utiliza en este trabajo, no es una tarea trivial, pues se tienen mucho más parámetros involucrados a la vez, además de la diferenciación de la serie de tiempo de forma regular y estacional. Sin embargo, los diagramas de ACF y PACF permiten proponer un modelo a partir de las formas teóricas de los procesos AR y MA.

Para definir la ACF y PACF se tienen las siguientes expresiones, obtenidas de (Brockwell & Davis, 2016). A pesar de ser ampliamente utilizadas y conocidas, son presentadas con el fin de robustecer el marco teórico del trabajo. Note que todas son estimaciones muestrales de parámetros poblacionales que definen a los procesos $AR(p)$, $MA(q)$ y $ARMA(p, q)$

Sean $\{x_1, \dots, x_n\}$ realizaciones de una serie de tiempo. La media muestral se calcula como:

$$\bar{x} = \frac{1}{n} \sum_{t=1}^n x_t \quad (9)$$

La función de autocovarianza muestral para el retraso (*lag*) h es:

$$\hat{\gamma}(h) = \frac{1}{n} \sum_{t=1}^{n-|h|} (x_{t+|h|} - \bar{x})(x_t - \bar{x}) \quad ; \quad -n < h < n \quad (10)$$

La función de autocorrelación (ACF) muestral para el retraso h , $\hat{\rho}(h)$, se muestra en la Ecuación 11. Observe que para $h = 0$, $\hat{\rho}(0) = 1$. En los autocorrelogramas muestrales que son presentados en este trabajo, es omitido incluir el retraso 0. Para fines de identificación del orden de un modelo, para un proceso $MA(q)$ causal, $\hat{\rho}(h = 0)$ para cualquier $h > q$

$$\hat{\rho}(h) = \frac{\hat{\gamma}(h)}{\hat{\gamma}(0)} \quad (11)$$

La función de autocorrelación parcial (PACF) muestral para el retraso h , $\hat{\alpha}(h)$, se muestra en la Ecuación 12. De manera análoga a la ACF se tiene que $\hat{\alpha}(0) = 1$, sin importar el proceso que se analice. Para un proceso $AR(p)$ se tiene que $\hat{\alpha} = 0$ para cualquier $h > p$.

$$\hat{\alpha}(h) = \hat{\phi}_{hh} \quad (12)$$

donde $\hat{\phi}_{hh}$ es el último componente del vector $\hat{\phi}_h$.

$$\hat{\phi}_h = \hat{\Gamma}_h^{-1} \hat{\gamma}_h \quad (13)$$

$$\hat{\Gamma}_h = [\hat{\gamma}(i-j)]_{i,j=1}^h \quad ; \quad \hat{\gamma}_h = [\hat{\gamma}(1), \dots, \hat{\gamma}(h)]$$

Estos dos estadísticos son ampliamente utilizados para proponer el orden de un modelo. Al ser estimaciones muestrales, los valores obtenidos tienen una variabilidad intrínseca que no asegura que lo observado sea realmente representativo del proceso que generó la realización X_t . Por lo tanto, se tienen que hacer pruebas de hipótesis que ayuden a tomar decisiones en este ambiente de incertidumbre.

Como ya se explicó, los procesos $MA(q)$ y $AR(p)$ tienen un comportamiento conocido para la ACF y PACF respectivamente. De manera que la prueba de hipótesis se formula para conocer si en un cierto retraso h , $\hat{\rho}(h)$ o $\hat{\alpha}(h)$ son igual a 0 y si existe evidencia estadísticamente significativa para suponerlo a un cierto nivel de confianza.

En (Tsay, 2005) se presenta la prueba de hipótesis que define si hay evidencia significativa para aceptar o rechazar que $\hat{\rho}(h) = 0$. El estadístico de prueba es:

$$t - ratio = \frac{\hat{\rho}(h)}{\sqrt{\frac{1}{n} \left(1 + 2 \sum_{i=1}^{h-1} \hat{\rho}(i)^2 \right)}} \quad (14)$$

Para una n grande, si Y_t es una serie Gaussiana estacionaria independiente e idénticamente distribuida, se espera que el $t - ratio$ tenga una distribución asintóticamente normal. En consecuencia, se espera que el $(1 - \alpha) \%$ de las $\hat{\rho}(h)$ sean igual a 0, con α un nivel de significancia dado. Para establecer intervalos de confianza para el ACF muestral, donde $H_0 : \hat{\rho}(h) = 0$ y $H_a : \hat{\rho}(h) \neq 0$, se utiliza en la Ecuación 15. De la Ecuación 12 se observa que la PACF es función de la ACF, por lo que también le aplican.

$$\text{Rechazar } H_0 \text{ si: } |\hat{\rho}(h)| \geq \frac{Z_{\alpha/2}}{\sqrt{n}} \quad (15)$$

donde $Z_{\alpha/2}$ es el $100(1 - \alpha/2)$ percentil de la distribución normal estándar.

De la Ecuación 10 observe que para calcular $\hat{\rho}(n - 1)$ únicamente se tomaría en cuenta un sumando, por lo que la estimación del parámetro estaría altamente sesgada, pues se incluye escasa información de la muestra. En (Huang & Pethukina, 2022) se presenta una “regla de dedo” para decidir el número de retrasos a tomar en cuenta para analizar las ACF y PACF muestrales: Para muestras con $n > 50$ el número de retrasos que se espera que tengan información relevante son $n/4$. Para este trabajo se consideran 30 retrasos.

En la Figura 10 se vuelve a mostrar la serie X_t , que es la transformación por Box Cox ($\lambda = -0.239935$) de los momios del porcentaje del almacenamiento aprovechable y que además se incluyen las gráficas con la ACF y PACF muestrales. El diagrama de ACF muestra que a lo largo de los 30 retrasos (h) analizados se tienen valores fuera del intervalo de confianza al 95 % para la prueba de hipótesis presentada en la Ecuación 15. Esto es evidencia de que un proceso $MA(q)$ no sería adecuado para su modelación. Por su parte, el PACF sugiere un comportamiento más adecuado, pues a partir del retraso 13, ningún $\hat{\alpha}(h)$ es significativamente distinto de 0, lo cual sería congruente con el comportamiento teórico de los procesos autoregresivos.

Un modelo $AR(13)$ podría ser un punto de partida para la modelación, sin embargo, el comportamiento, aparentemente cíclico, del ACF no respalda la decisión de utilizar este

modelo. Además, se observa que a partir de 2019 existe una tendencia descendente en la serie de tiempo, lo cual podría causar problemas de estacionariedad. Para remover la tendencia se utiliza una filtro de diferenciación regular de un retraso.




Figura 10: Serie $X_t^{(0,0)}$ con diagramas de ACF y PACF muestrales

La diferenciación podría entenderse como una transformación que busca remover la tendencia, pero en el contexto de procesos SARIMA(p, d, q)x(P, D, Q), la diferenciación regular también establece el orden asignado a d . Esto constituye el primer paso en la definición del modelo. La notación propuesta para identificar las series de tiempo diferenciadas es $X_t^{(d,D)}$, donde $X_t = X_t^{(0,0)}$. La primera diferenciación propuesta es $X_t^{(1,0)}$ donde:

$$X_t^{(1,0)} = (1 - B)X_t = X_t - X_{t-1} \quad (16)$$

En la [Figura 11](#) se muestra la serie $X_t^{(1,0)}$, así como los diagramas de ACF y PACF. Se observa que la serie de tiempo es, en apariencia, mucho más estacionaria con media 0. La forma de la serie de tiempo es más regular para cada año, pero en 2010 se observa una anomalía, que se explica en que para ese año no existió un periodo de estiaje notable (ver la [Figura 7](#)). En el ACF se nota que la forma cíclica se incrementa, donde valores significativamente distintos de 0 cada dos retrasos. Del PACF se observa que el filtro de diferenciación ayudo a hacer más nítidas las características del proceso, pues se podría proponer un modelo AR(8) como punto de partida en la modelación.

Al análisis anterior se añade que la serie $X_t^{(1,0)}$ muestra una clara estacionalidad, cada cuatro tiempos se presenta una cresta o un valle. El periodo S es 4, pues es el número




Figura 11: Serie $X_t^{(1,0)}$ con diagramas de ACF y PACF muestrales

de pasos en el tiempo para los que se encuentra la estacionalidad. Remover los efectos de estacionalidad se logra al utilizar un filtro de diferenciación estacional. Note que este filtro debe ser superpuesto al ya aplicado; el orden de aplicación de las diferenciaciones regulares y estacionales es indiferente, porque el operador diferencia puede operar como un polinomio. La nueva serie $X_t^{(1,1)}$ se obtiene como:

$$X_t^{(1,1)} = (1 - B^4)X_t^{(1,0)} = (1 - B^4)(1 - B)X_t = (X_t - X_{t-1}) - (X_{t-4} - X_{t-4-1}) \quad (17)$$

La serie $X_t^{(1,1)}$, así como sus respectivos diagramas de ACF y PACF muestrales, se muestran en la [Figura 12](#). Su forma sugiere que es estacionaria con media en cero. Note que aparenta tener un comportamiento estacional, pero este no muestra una frecuencia clara, por lo que no se perseguirán mayores diferenciaciones, tanto regulares como estacionales. El diagrama del PACF muestra que $\hat{\alpha}(1) \neq 0$, lo que sugiere proponer $p = 1$. A cada cuatro retrasos los valores de $\hat{\alpha}(h)$ se salen de los intervalos de confianza, lo que es evidencia de que podría existir una componente autorregresiva estacional en el proceso por modelar. Una excepción es en el retraso de orden 7, pero se asume que podría deberse a variabilidad muestral, no a una característica del proceso. Como el último que sale de las bandas de confianza es el del retraso 16, y la frecuencia del fenómeno es de 4 periodos, se propone un orden $P = 16/4 = 4$. Lo observado en el ACF se asume como propio del modelo, sin que arroje sugerencias claras sobre el orden de q o Q .

El modelo propuesto es de la forma SARIMA(1, 1, 0)x(4, 1, 0). Para este se estimarán los parámetros y se evaluará la validez de los supuestos, para asegurarse que las predicciones hechas a partir de éste tengan validez estadística, o si se tendría que buscar otro modelo.




Figura 12: Serie $X_t^{(1,1)}$ con diagramas de ACF y PACF muestrales

3.3. Estimación de parámetros

Definido el orden del modelo, los siguientes pasos en el proceso de modelación son asegurarse de que la serie por modelar sea estacionaria, estimar los parámetros utilizados, evaluar su significancia estadística y revisar si los estimadores cumplen con el supuesto de estacionariedad.

Para revisar la estacionariedad en la serie por modelar se utiliza una prueba de raíz unitaria. En la teoría de series de tiempo se puede demostrar que un proceso estocástico es estacionario en el caso de que se encuentren dentro del círculo unitario todas las raíces del polinomio autorregresivo, definido por el operador autorregresivo. La prueba de Dickey-Fuller Aumentada rechaza la hipótesis nula de que una raíz unitaria se encuentre fuera del círculo unitario. La prueba se basa en el supuesto de que la diferenciación de una serie de tiempo es un método eficiente para remover la tendencia que sea contraria al supuesto de estacionariedad.

Para verificar la existencia de una raíz unitaria en un proceso $AR(p)$ se puede conducir la prueba de que $H_0 : \beta = 0$ contra $H_a : \beta < 1$ usando la regresión siguiente (Tsay, 2005).

$$y_t = \beta y_{t-1} + \sum_{u=1}^{p-1} \phi_u \Delta y_{t-u} + e_t \quad (18)$$

$$ADF - test = \frac{\hat{\beta} - 1}{std(\hat{\beta})} \quad (19)$$

El estadístico de prueba se compara contra un valor de -2.86 para un nivel de confianza del 5%. Note que el valor de corte de esta prueba es mucho mayor que la esperada para una prueba normal para que se menos probable cometer un error Tipo 2. La forma más práctica de conducir estas pruebas es usar paquetería estadística. Utilizando R, la librería *forecast* y la función *adf.test()*. En la [Tabla 4](#) se presentan los resultados para la serie diferenciada $X_t^{(1,1)}$.

ADF-test	-6.0251
p-valor	< 0.01
Interpretación	Se rechaza H_0 . No existen raíces fuera del círculo unitario. La serie es estacionaria

Tabla 4: Prueba Dickey-Fuller Aumentada de estacionariedad

El requerimiento esencial para la modelación con series de tiempo ha sido validado, por lo se procede a estimar los parámetros. Recuerde que se propuso un modelo SARIMA(1,1,0)x(4,1,0). Recuerde que la forma general es $\phi(B)\Phi(B^S)X_t = \theta(B)\Theta(B^S)\epsilon_t$, por lo que se tiene que:

$$\phi(B) = (1 - \phi_1)$$

$$\Phi(B) = (1 - \Phi_1 B - \Phi_2 B^2 - \Phi_3 B^3 - \Phi_4 B^4)^4$$

$$\theta(B) = 1$$

$$\Theta(B) = 1$$

Adicionalmente, recuerde que $\epsilon_t \sim N(0, \sigma^2)$. Por lo tanto, son $m = 6$ el número total de parámetros a estimar. El método de mínimos cuadrados tiene una interpretación intuitiva, pero en ciertas ocasiones, las estimaciones obtenidas por este método no son las óptimas. Por lo tanto, las estimaciones de los parámetros que se presentan en este trabajo son calculadas con el método de máxima verosimilitud.

De ([Brockwell & Davis, 2016](#)) se rescatan las siguientes ideas. La estimación por máxima verosimilitud depende de la suposición de una forma distribucional particular de las observaciones, conocida aparte de los valores de los parámetros $\theta = [\theta_1, \dots, \theta_m]$. Note que, para el desarrollo de estas definiciones, los parámetros θ son distintos a los pertenecientes a los polinomios de medias móviles. Se puede considerar el problema de estimación de parámetros como el de selección de un vector θ , que toma valores en un subconjunto $\Theta \in \mathbb{R}^m$ (el soporte del espacio parametral). Se hace la suposición de que éstas distribuciones tienen la función de densidad de probabilidad $p(\mathbf{x}|\theta)$, la cual se llama la función de verosimilitud. Un estimador por máxima verosimilitud $\hat{\theta}$ es un valor de $\theta \in \Theta$ que maximice el valor de $L(\theta)$ para una colección de observaciones $\mathbf{x} = \{x_1, \dots, x_n\}$ dadas.

$$L(\hat{\theta}) = p(\mathbf{x}|\hat{\theta}) = \max [p(\mathbf{x}|\theta)] \quad (20)$$

Resolver de manera analítica problema de maximización, muchas veces es una tarea poco práctica y en ocasiones sin solución conocida. Es por eso que los algoritmos de métodos numéricos son ampliamente utilizados y en las últimas décadas han abierto las puertas a la resolución de problemas de mayor complejidad.

La verosimilitud en el contexto de series de tiempo es casi siempre utilizado en el sentido de verosimilitud Gaussiana, es decir que se hace el supuesto de que la serie sea Gaussiana. Sin embargo, las estimaciones de coeficientes en procesos ARMA calculados por la maximización de la verosimilitud Gaussiana tienen buenas propiedades en muestras grandes. Estas propiedades se refieren a que se tenga un sesgo relativamente pequeño y que el teorema del límite central pueda ser aplicado.

La estimación de parámetros por máxima verosimilitud lleva a un valor particular, a veces conocidas como estimación puntual. Es claro que este nunca será exactamente igual al parámetro verdadero, por lo que es importante que se comunique una medida de la precisión del estimador. Esto se logra utilizando el concepto de intervalo de confianza, el cual proporciona una medición de la variabilidad muestral que se espera de la estimación.

La estimación de parámetros se hizo en R con la librería *forecast* y la función *Arima()*, los resultados se muestran en la [Tabla 5](#). La serie fue diferenciada de acuerdo a las especificaciones del modelo ($d = 1, D = 1$), por lo que el número de observaciones se redujo de 123 a 118, cuatro por la diferenciación estacional y una por la diferenciación regular.

Parámetro	Estimación	Error estándar	$\Pr(> z)$
$\hat{\phi}_1$	0.332286	0.090750	0.00025
$\hat{\Phi}_1$	-0.771525	0.093489	<0.00001
$\hat{\Phi}_2$	-0.706074	0.113405	<0.00001
$\hat{\Phi}_3$	-0.371980	0.112126	0.00091
$\hat{\Phi}_4$	-0.206903	0.095625	0.03049

Tabla 5: Valores estimados de los parámetros

Note que $\Pr(> |z|)$ corresponde al p-valor de la prueba de hipótesis de Wald con $H_0 : \hat{\theta} = 0$ contra $H_0 : \hat{\theta} \neq 0$. A excepción de $\hat{\Phi}_4$, todos los estimadores son significativos en un nivel de confianza mayor al 99.9 %, siendo éste último significativo en un nivel de confianza del 95 %, por lo que los resultados obtenidos se aceptan y se procede con la modelación.

Para el caso de $\hat{\sigma}^2$ se obtiene una estimación puntual de 0.067363 con un intervalo de confianza al 95 % de (0.05269, 0.08917). Para este estimador no se presenta ninguna prueba de hipótesis debido a que solo ayuda a entender el modelo, no a evaluar su significancia.

Además de conocer los valores puntuales se debe de corroborar que éstos conformen un proceso estocástico causal. La forma de realizar esta revisión es expandiendo los polinomios autorregresivos y obtener las raíces. Ninguna raíz debe estar dentro del círculo unitario. En otra palabras, la inversa de éstas debe de estar fuera. La definición exacta

del polinomio no es puesta en el trabajo, debido a su tamaño. Las raíces son calculadas directamente utilizando R, como un resultado del ajuste del modelo. En la [Figura 13](#) se muestran los valores de las 17 raíces del polinomio autorregresivo. Se observa que todas están dentro y lejos de la colindancia con el círculo unitario, por lo que se cumple con la condición de estacionariedad del modelo ajustado.




Figura 13: Raíces del polinomio autorregresivo

Las estimaciones obtenidas y la significancia calculada son sugerencia de que ha sido correcta la definición del modelo y de que el orden seleccionado es el adecuado. A pesar de que a partir de este momento se pueden obtener predicciones, es necesario validar los supuestos que se hicieron sobre el modelo para tener certeza sobre éstas.

3.4. Validación de supuestos

Una vez definidos los estimadores puntuales se procede a evaluar los supuestos que den garantía sobre la calidad de las predicciones realizadas con el modelo. Los tres supuestos sobre los residuales que serán puestos a prueba son: la no autocorrelación, la normalidad y la homoscedasticidad. Para cada una se presenta una prueba estadística que permita aceptar o rechazar el cumplimiento de éstos con un nivel de significancia dado.

Recuerde que los residuales (r_i) se calculan de la siguiente manera:

$$e_i = r_i = y_i - \hat{y}_i \quad (21)$$

En la [Figura 14](#) se muestran los residuales del modelo. Observe que las primeras 5 observaciones no se muestran, esto es debido a que el residual es 0, pues son observaciones de arranque para el modelo; el número de observaciones está dado por el orden de los hiperparámetros d (se resta una observación por cada unidad) y D (se restan cuatro observaciones por unidad). Note que están dado en medidas de los momios (*odds*), por lo

que carecen de una interpretación directa en el nivel de almacenamiento. salvo el signo, cuando el residual es positivo implica que el modelo predijo un valor de almacenamiento, pero en realidad se observó uno menor. Sin embargo, esta comparación no es intuitiva debido a que la transformación inversa es compleja.




Figura 14: Raíces del polinomio autorregresivo

La primera prueba que se aplica es la de no autocorrelación. En la [Figura 15](#) se exhibe la función de autocorrelación muestral de los residuales. Se observa que para el retraso 13 se sale del intervalo de confianza. Sin embargo, que el resto esté dentro es sugerencia de que tal vez sea una perturbación muestral, más que un fenómeno poblacional.

Para corroborar este supuesto se utiliza la prueba estadística de Portmanteau bajo la modificación de Ljung-Box ([Tsay, 2005](#)). Se prueba conjuntamente bajo H_0 que $\rho_1 = \rho_2 = \dots = \rho_m = 0$, con una hipótesis alternativa $H_a : \rho_i \neq 0$ para $i \in (1, \dots, m)$. Bajo el supuesto de que $\{r_i\}$ es una secuencia independiente e idénticamente distribuida con ciertas condiciones de momentos, el estadístico $Q(m)$ que se muestra en la [Ecuación 22](#) asintóticamente se distribuye como χ_m^2 .

$$Q(m) = N \sum_{i=1}^m \frac{\hat{\rho}_i^2}{N-i} \quad (22)$$

La prueba se realiza utilizando R, la paquetería *forecast* y la función `Box.test(lag=30, type="Ljung")`. Observe que el número de lags efectivos se toman como 30, por motivos previamente discutidos. Los resultados se muestran en la [Tabla 6](#). La prueba indica que no existe autocorrelación entre los residuales, por lo que se valida este supuesto.

El segundo supuesto a probar es el de homoscedasticidad. Este contempla que la varianza (σ^2) de los residuales sea constante, lo que significa que sea independiente del tiempo.




Figura 15: ACF de los residuales

Ljung-Box	37.294
p-valor	0.1687
Interpretación	No se rechaza H_0 $\rho_1 = \dots = \rho_{30} = 0$

Tabla 6: Prueba Ljung-Box de autocorrelación

De (Tsay, 2005) conocemos que existen diversas pruebas para corroborar este supuesto, como la de Breusch-Pagan o la de White. Sin embargo, estas no son específicas para el contexto de series de tiempo, por lo que la que se utilizará aquí será una prueba de ARCH de Engle. (autorregresivo con heteroscedasticidad condicional, por sus siglas en inglés)

La prueba ARCH de Engle está basada en el hecho de que si los residuales son heteroscedásticos, entonces el cuadrado de estos están autocorrelacionados. La prueba se basa en los multiplicadores de Lagrange al ajustar un modelo de regresión para los errores cuadrados en hasta q retrasos. En la Tabla 7 se muestran los resultados obtenidos en R con la librería *forecast* y la función *Arch.Test()*.

χ^2	24.213
p-valor	0.763
Interpretación	No se rechaza H_0 No se encuentran efectos ARCH

Tabla 7: Prueba ARCH de Engle de heteroscedasticidad

Por último se revisa el supuesto de normalidad de los residuales. Existen diversas pruebas de normalidad como las de Shapiro-Wilks, Anderson Darling, etc. De acuerdo con (Tsay, 2005) la que es más adecuada para el contexto de series de tiempo es la de Jarque-Bera. Esta prueba se basa en las estimaciones muestrales del sesgo $\hat{S}(x)$ y la kurtosis $\hat{K}(x)$, cuyo cálculo se muestran en la Ecuacion 23, donde $\hat{\sigma}$ es la desviación estándar muestral.

$$\hat{S}(x) = \frac{1}{(N-1)\hat{\sigma}^3} \sum_{i=1}^N (x_i - \bar{x})^3 \quad ; \quad \hat{K}(x) = \frac{1}{(N-1)\hat{\sigma}^4} \sum_{i=1}^N (x_i - \bar{x})^4 \quad (23)$$

El estadístico de prueba JB que se muestra en la Ecuacion 24 se distribuye asintóticamente como $\chi_{(2)}^2$. La hipótesis nula es que la muestra se distribuye como una normal y se rechaza si el p-valor asociado a JB es menor al nivel de significancia α .

$$JB = \frac{\hat{S}^2(x)}{6/T} + \frac{[\hat{K}(x) - 3]^2}{24/N} \quad (24)$$

De la misma manera, la prueba se realizó en R con la librería *forecast* y con la función *jarque.bera.test()*. Los resultados se muestran en la Tabla 8. En esta ocasión el supuesto no pudo ser validado.

JB	9.176
p-valor	0.010
Interpretación	Se rechaza H_0 Los residuales no se distribuyen normalmente

Tabla 8: Prueba Jarque-Bera de normalidad

A pesar de que solo 1 de los 3 supuestos no se cumplen, no es sensato validar el modelo, pues las predicciones derivadas no tendrán significancia estadística. Recuerde que los hiperparámetros fueron seleccionados a partir de una inspección visual de los diagramas de ACF y PACF de las series diferenciadas, por lo que se procederá a buscar algún modelo que sea válido que cumpla con los tres supuestos.

3.5. Optimización del modelo

Es una tarea compleja el establecer un conjunto de hiperparámetros que satisfagan los supuestos de los residuales y los requerimientos de estacionariedad e invertibilidad. Para tal motivo se realiza una búsqueda en malla y se seleccionará el modelo válida con un menor AIC (Akaike Information Criterion, por sus siglas en inglés).

El AIC es un criterio de información basado en la verosimilitud. Es utilizado para establecer el orden de los hiperparámetros en algunos modelos, así como para comparar múltiples modelos anidados y seleccionar el que mayor predictivo aporte con el menor número de parámetros, con el fin de reducir el riesgo de sobreajuste. En la Ecuacion 25 se muestra la forma en que se calcula. El modelo que se prefiere es aquel que obtenga un AIC menor. Observe que se pueden obtener valores negativos, por lo que la comparación no se

hace en valores absolutos, sino que se respeta la recta numérica para seleccionar un modelo. También note que el AIC es un calificador que castiga por el número de parámetros ajustados, por lo que garantiza un enfoque que busca la parsimonia en el modelo ganador.

$$AIC = -\frac{2}{N} \log [L(\hat{\theta})] + \frac{2}{N} (\text{número de parámetros}) \quad (25)$$

Debido a que su cálculo se basa en la verosimilitud, la comparación de modelos mediante AIC requiere que los modelos en cuestión sean anidados y que estén entrenados con el mismo conjunto de datos. De otra manera, es imposible comparar los modelos, pues el AIC no arroja información comparable.

Los modelos, a pesar de que todos sus coeficientes sean significativos y, aparentemente, ajusten bien a los datos, no siempre son candidatos a ser un modelo válido. Realizar una búsqueda basada únicamente en el AIC sería inútil pues adicionalmente se tienen que ir validando los supuestos.

Es indispensable recordad que los hiperparámetros d y D en realidad lo que hacen es diferenciar la serie para que un proceso ARMA sea ajustado, por lo que al ir variando estos, diferentes series de datos son ajustadas y no sería posible realizar la comparación mediante el AIC entre un modelo con hiperparámetros (d_1, D_1) con uno (d_2, D_2) , a pesar de que el resto de hiperparámetros sean idénticos, pues la serie de datos a la que se ajustan no es la misma.

Para seleccionar un modelo ganador entre las diferentes parejas de hiperparámetros (d, D) se utiliza una métrica que evalúe la bondad de ajuste de manera numérica, sin la necesidad de que los modelos sean anidados. Para este trabajo se utiliza el error cuadrático medio (RMSE, por sus siglas en inglés). En la [Ecuación 26](#) se muestra su forma de cálculo. El modelo ganador será aquel que tenga un RMSE menor, entre aquellos modelos seleccionados como los mejores, de acuerdo con el AIC, dentro de su familia de modelos con el mismo valor de (d, D) .

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (26)$$

Una vez definidas las métricas de evaluación, se procede a realizar la búsqueda en malla. El conjunto de hiperparámetros que se analizan en la búsqueda en malla son los siguientes. $p \in (0, 1, \dots, 6)$, $d \in (0, 1, \dots, 4)$, $q \in (0, 1, \dots, 4)$, $P \in (0, 1, \dots, 6)$, $D \in (0, 1, \dots, 4)$ y $Q \in (0, 1, \dots, 4)$. Por lo tanto, se intentarán ajustar $7 \times 5 \times 5 \times 7 \times 5 \times 5 = 30,625$ modelos diferentes que serán evaluados. Para este ejercicio, el script escrito por el autor tomó alrededor de 6 horas. Reducir la búsqueda para los hiperparámetros de medias móviles fue necesario para que no se demorara en exceso.

La malla de búsqueda pareciera que fue arbitrariamente seleccionada, pero fue el resultado de un análisis iterativo, buscando mejorías en algunos puntos de la malla y redefiniendo el área de búsqueda.

A cada modelo se le realizan las pruebas de raíces unitarias, tanto para el polinomio autorregresivo como el de medias móviles, pruebas de significancia para los parámetros estimados y las pruebas de supuestos sobre los residuales. Solo aquellos modelos que cumplan con todas las pruebas y cuyos parámetros sean significativos en su totalidad, con al menos un nivel de significancia del 5 %, serán candidatos para ser seleccionados como el modelo ganador con el que se realizará el resto del análisis.

En la [Tabla 9](#) se muestran el número de modelos que cumplen con todas las pruebas para cada combinación de hiperparámetros (d, D) , de un total de 1,225 modelos para dicha familia. Entre paréntesis se muestra el valor de AIC para el modelo con menor valor dentro de la familia de modelos y el RMSE de dicho modelo. Note que en total solo 90 de los 30,625 modelos posibles pueden ser considerados como válidos.

d	D				
	0	1	2	3	4
0	0 (-, -)	0 (-, -)	4 (63, 2.6)	9 (117, 4.5)	5 (211, 10.9)
1	0 (-, -)	1 (58, 3.9)	8 (70, 2.9)	7 (141, 6.2)	4 (228, 28.1)
2	2 (115, 11.9)	8 (58, 3.0)	6 (108, 4.2)	4 (170, 10.8)	4 (263, 74.3)
3	0 (-, -)	12 (85, 3.4)	10 (136, 5.4)	1 (214, 11.3)	1 (259, 302.5)
4	0 (-, -)	3 (144, 5.12)	1 (108, 7.16)	0 (-, -)	0 (-, -)

Tabla 9: Modelos válidos y (AIC, RMSE) del mejor en la búsqueda en malla

El modelo ganador se selecciona de la familia con hiperparámetros $(d = 0, D = 2)$, pues el modelo con un AIC menor dentro esta familia es el que tiene el RMSE menor entre todas las familias. Observe que no es el que minimiza el AIC de toda la malla, pero ya se discutió que no es posible realizar la comparación entre diferentes valores de éstos hiperparámetros, pues la serie de datos a la que se ajustan es diferente.

La forma del modelo ganador es SARIMA(2,0,0)x(4,2,0). Este modelo cumple con todas las pruebas antes mencionadas, además de que es el que minimiza el error cuadrático medio entre todos los demás modelos válidos. Para el resto del análisis se toma este modelo. En la [Figura 16](#) se muestra la forma de la serie de tiempo con hiperparámetros $(d = 0, D = 2)$, junto con sus diagramas de ACF y PACF muestrales. Se observa que a partir de los autocorrelogramas no es posible identificar el modelo obtenido. Es por eso

que la búsqueda en malla ofrece una forma más eficaz de seleccionar los hiperparámetros de un modelo ganador que ajuste a los datos observados y explique el fenómeno en estudio.




Figura 16: Serie $X_t^{(0,2)}$ con diagramas de ACF y PACF muestrales

En la [Tabla 10](#) se muestran los valores de los estimadores de los parámetros, al igual que sus pruebas de significancia. Es importante destacar que, a pesar de que se aumentó el número de parámetros con respecto al primer modelo propuesto, para el caso del modelo final, todos los parámetros son significativos a un nivel de significancia menor al 0.1%, lo que es una buena señal de que hubo una mejora en la modelación.

Parámetro	Estimación	Error estándar	$\Pr(> z)$
$\hat{\phi}_1$	1.226	0.086	< 0.001
$\hat{\phi}_2$	-0.437	0.091	< 0.001
$\hat{\Phi}_1$	-1.217	0.100	< 0.001
$\hat{\Phi}_2$	-1.195	0.139	< 0.001
$\hat{\Phi}_3$	-0.782	0.133	< 0.001
$\hat{\Phi}_4$	-0.386	0.092	< 0.001

Tabla 10: Estimadores de los parámetros del modelo final

Con un modelo final es importante remarcar que la interpretación de parámetros no es una tarea sencilla para los modelos SARIMA, debido a las diferenciaciones y al cruce de parámetros. Por lo tanto, en este trabajo no se intenta hacer una traducción entre

los valores de los parámetros con el comportamiento esperado en la serie de datos original.

Después se revisa el requerimiento de estacionariedad por medio de raíces unitarias. No se revisa el de invertibilidad, pues no existen coeficientes de medias móviles. En la [Figura 17](#) se observa que todos las raíces se encuentran dentro del círculo unitario, por lo que, efectivamente, el modelo es el de un proceso estacionario. Note que el se agrega una raíz en comparación con el modelo anterior.




Figura 17: Raíces unitarias del modelo final

Por último, en la [??](#) se muestran los resultados de las pruebas para garantizar los supuestos de independencia, homoscedasticidad y normalidad. Todas cumplen a un nivel de significancia del 5 %, por lo que el modelo presentado es válido para la obtención de predicciones, que son presentadas en el capítulo siguiente.

Prueba	Estadístico	p-valor	Conclusión
Ljung-Box	26.9	0.626	Independiente
ARCH de Engle	28.9	0.521	Homoscedastico
Jarque-Bera	4.75	0.093	Normal

Tabla 11: Validación de supuestos de los residuales del modelo final

4. Resultados y conclusiones

4.1. Validación de predicciones

Al identificar el orden del proceso por ajustar (o el valor de los hiperparámetros), el siguiente paso es hacer una evaluación (no matemática) de las predicciones que se pueden obtener del modelo. Realizar este proceso brinda confianza adicional sobre las operaciones matemáticas, pues ofrece una prueba empírica sobre el poder del predictivo y capacidades del modelo ajustado.

Primero se comparan los valores observados con los ajustados por el modelo. En la [Figura 18](#) se muestra el cotejo de ambas series. Observe que la serie no comienza en 1994 como los datos originales, debido a que son necesarios valores de arranque que no pueden ser recuperados (a menos que se asuman iguales a los observados), ocasionados por el orden de los parámetros de diferenciación ($d = 0, D = 2$).

Para algunos puntos específicos el ajuste no es tan bueno, como la temporada de lluvia en 2010, donde se esperaba una reducción del nivel de las presas, pero al contrario hubo un aumento, lo que representa una condición totalmente atípica en los 30 años de registros. Esta gráfica nos demuestra que el modelo es capaz de reproducir de manera satisfactoria los valores observados, por lo que es un primer indicio de confianza sobre el ajuste en general.




Figura 18: Comparación del ajuste del modelo con lo observado

La segunda validación empírica que se realiza es sobre el poder predictivo del modelo entrenado. Para llevar a cabo esta prueba se eliminan las últimas h observaciones en la serie de datos original y se procede a entrenar el modelo suponiendo que en realidad

no se conocen éstas h observaciones. La prueba radica en investigar si los intervalos de confianza de predicción del modelo contienen a los valores observados que se ocultan al entrenamiento del modelo.

Esta prueba, además de validar el modelo, permite ganar confianza sobre las predicciones que se realicen en el futuro que realmente no ha sido observado, pues si los valores que permanecen ocultos están dentro del intervalos de confianza de las predicciones es indicador de que el modelo es capaz de reproducir los siguientes pasos en una serie de tiempo. En la [Figura 19](#) se muestra dicha prueba, considerando como desconocidos las últimas $h = 8$ valores (temporadas), es decir, los últimos 2 años.

La prueba descrita anteriormente es conocida como *backtesting* en el argot de ciencia de datos. En la [Figura 19](#) se muestran los resultados del *backtesting* con $h = 8$. Se observa que el modelo fue capaz de reproducir satisfactoriamente la totalidad de los datos, pues se encuentran dentro del intervalo del 80 % de confianza. Vale la pena destacar que los últimos 6 registros se encuentran muy por debajo de la predicción puntual del modelo, lo que indica que la crisis por la que atraviesa el Sistema no se esperaba bajo condiciones normales, sino que realmente es producto de un escenario atípico.

El intervalo de confianza es la métrica más importante, pues es 0 la probabilidad de que el nuevo valor observado sea igual a la estimación puntual. Al final de los 8 periodos de predicción el intervalo de confianza es de (8.3 %, 54.4 %) del almacenamiento, para un nivel de confianza del 95 %. Por lo tanto, desde hace dos años era posible determinar que nos enfrentaríamos ante un escenario de escasez de agua y que el nivel de almacenamiento de las presas sería bajo.




Figura 19: *Backtesting* del modelo

4.2. Predicciones para 2025 y 2026

El último paso del proceso de modelación es obtener las predicciones para el futuro. Se han realizado todas las pruebas, necesarias para tener confianza en éstas, por lo que la interpretación de los intervalos de confianza resultantes son el mensaje fundamental que se ha buscado a través de de todo el trabajo.

Las predicciones son resultado del aprendizaje del comportamiento histórico del proceso. La capacidad de recuperación en la temporada de lluvias y magnitud de la recesión en ls temporadas de estiaje, están definidas por lo que ya ha ocurrido. La cantidad de agua escurrida hasta los embalses y las políticas de extracción en las presas son fenómenos que se intentan simplificar en el ajuste del modelo, por lo que las proyecciones realizadas están sujetas a la variabilidad de estos fenómenos exógenos.

Para obtener las predicciones entrena el modelo con todas la información disponible (desde Invierno (DEF) 1994 hasta Verano (JJA) 2024). En la [Figura 20](#) se muestran los valores de la predicción para Otoño (SON) 2024; Invierno (DEF), Primavera (MAM), Verano (JJA) y Otoño (SON) 2025; y Diciembre (DEF) y Primavera (MAM) 2026.

Una vez más se remarca que la predicción de interés es la del intervalo de confianza y no la estimación puntual, pues ofrece un panorama de certidumbre más amolío para la toma de decisiones. Se observa que la proyección no contempla que el Sistema regrese a niveles altos promedio, como en el periodo entre 2015 y 2019, sino que es latente el riesgo de continuar en periodos de escasez hídrica.




Figura 20: Predicciones para 2025 y 2026

4.3. Conclusiones

Contar con agua potable es esencial para el desarrollo de la humanidad. Asegurar un suministro constante y de calidad suficiente es una labor primordial de la ingeniería civil, pues habilita el desarrollo social y económico de la población. Cuando las fuentes de agua dependen directamente de la precipitación, su gestión se enfrenta a una complejidad adicional, causada por la variabilidad intrínseca de la lluvia. Los métodos estadísticos son las herramientas adecuadas para comprender los fenómenos estocásticos, como lo es la precipitación. Estos exigen que su aplicación sea metódica y cautelosa, con la finalidad de obtener resultados significativos y garantizar que las decisiones que se tomen a partir de éstos, sean óptimas y consideren toda la información disponible en el análisis.

El Sistema Cutzamala ha sido ampliamente estudiado por su importancia económica, política y social. Trabajos como (Romero G., 2021) y (Hernández H., 2022) marcan un precedente reciente de su estudio a través de la aplicación de técnicas estadísticas (o de *Machine Learning*), con el fin de ganar comprensión sobre la disponibilidad hídrica en el Sistema. Sin embargo, tal como se menciona en (Estrada & Guerrero, 2013), la aplicación de técnicas estadísticas sin la cautela de revisar los supuestos fundamentales de los modelos, u omitiendo un riguroso proceso de validación, convierte a los análisis en el producto de artificios estadísticos, lo que compromete la validez de los resultados obtenidos.

Una de las prioridades que ha tenido este trabajo es evitar los errores mencionados anteriormente. Se logra mediante la revisión exhaustiva de los supuestos de los modelos y la validación de las predicciones obtenidas. Se han ganado experiencias importantes mediante el proceso de construcción del modelo, como que a pesar de que los resultados intermedios sean favorables, es necesario inspeccionar la totalidad de éstos antes de la aceptación del modelo.

La selección de datos empleados implica una ventaja respecto a los trabajos precedentes. Utilizar el nivel de almacenamiento en las presas del Sistema constituye una mejora en la calidad de la información. El primer motivo es que el periodo de cobertura fue de más de 30 años y la ocurrencia de datos faltantes fue mínima (menos del 0.5 %). El segundo motivo es que se dejan en términos estocásticos variables que no son modelables fácilmente de manera determinística, como el cambio de uso de suelos, tomas clandestinas, cambios en la política de operación, alteraciones en el régimen de precipitación, etc.

El proceso de modelación fue exitoso, se logró ajustar un proceso estocástico de series de tiempo que reproduce de manera adecuada los datos utilizados y que cumple con los supuestos matemáticos que dan certidumbre sobre las predicciones resultantes. Las transformaciones de datos utilizadas han sido parte clave de este resultado, pues permitieron llevar los datos a un dominio trabajable. Para la revisión de supuestos se utilizó una sola prueba de significancia, contrario a la práctica ingenieril en la que se realizan diferentes pruebas para un mismo supuesto y se toma un veredicto mediante voto mayoritario. La decisión de considerar solamente una prueba se basó en que en la literatura consultada, enfocados en series de tiempo, no se recomienda la decisión por ensamble, pues no es garantía de que la decisión que se toma sea más acertada, ya que en términos prácticos, ninguna prueba es superior a las demás.

En términos abstractos, los resultados fundamentales del trabajo fueron haber definido el orden del modelo y confirmar la validez de sus predicciones. Los resultados sirven a diferentes propósitos prácticos, mediante los cuales se brinda la mayor información posible para la toma de decisiones de diferentes grupos de interés. La adopción del modelo ayudaría a mejorar las políticas de operación de las presas, pues otorga una señal de alerta temprana sobre posibles periodos de escasez hídrica, lo que impulsaría a que las medidas de racionamiento se den en un momento que no sea crítico, sino que exista un periodo de antelación adecuado. Otra aplicación es la de comunicación sobre la disponibilidad en el Sistema a agentes no técnicos, como la sociedad civil, los medios de comunicación y los actores políticos. Durante la crisis actual se ha observado que los temas hídricos han ganado relevancia en la opinión pública, por lo que es esencial transmitir información de calidad. Adicionalmente, con el modelo es posible ganar entendimiento sobre los patrones de lluvia que existen en la región, por lo que se habilita la detección y evaluación de los impactos de cambio climático.

No existen los modelos estadísticos con la cualidad de predecir el futuro con exactitud; el que se presenta en este trabajo no es la excepción. Los intervalos de confianza sobre las predicciones presentadas ayudan a lidiar con la incertidumbre natural de las predicciones. Para 2025 y 2026 se espera que continúen las condiciones de escasez hídrica, ocasionadas por una baja recuperación en la temporada de lluvias (SON) de 2023. Es importante recordar que los procesos SARIMA cumplen con la propiedad de Markov a $\max(p, q, P, Q)$ pasos, lo que implica que la baja expectativa en la recuperación de los niveles de almacenamiento es ocasionada por los bajos niveles observados en los últimos 4 años (note que el hiperparámetro $P = 4$). Sin embargo, se tiene certeza de que la ocurrencia de una temporada de lluvias abundantes es posible en cualquier año, debido a que se asume que es un proceso independiente año tras año; como precedente las temporadas de lluvias de 1998, 2010 y 2014 (ver la [Figura 7](#)).

El entrenamiento del modelo con una nueva observación que se diferente a la estimación puntual, ocasionaría que se modifiquen los intervalos de confianza en el futuro. En consecuencia, los resultados mostrados, en vez de sugerir un futuro inamovible, reflejan uno futuro posible para el cual habría que estar preparados.

Para el futuro de esta investigación se sugieren las siguientes líneas. La primera sería llevar una validación periódica de la validez del modelo, volviendo a entrenar el modelo con los nuevos datos adquiridos. La segunda implica realizar un plan de adopción del modelo en procesos de toma de decisión por parte de las autoridades correspondientes. Por último, se sugiere entrenar modelos de *machine learning* con una capacidad predictiva superior, para mejorar el desempeño de las predicciones.

La hidroinformática es una disciplina que permite adaptarnos y mitigar las nuevas condiciones que impone el cambio climático, a través del análisis de los patrones de precipitación con técnicas más sofisticadas, habilitadas por la creciente capacidad de cómputo y la variedad de modelos predictivos que pueden ser ajustados. Adoptar técnicas que han sido validadas en otras disciplinas, para que los Ingenieros Civiles resuelvan sus problemas específicos, permitirá garantizar que las soluciones seas novedosas, optimizadas y que a través de éstas se mejoren las condiciones de la sociedad.

Referencias

- Banco Mundial. (2015). *Cutzamala: Diagnóstico Integral*. Comisión Nacional del Agua y Banco Internacional de Reconstrucción y Fomento.
- Brockwell, P. J., & Davis, R. A. (2016). *Introduction to Time Series and Forecasting* (3rd). Springer.
- CONAGUA. (2005). *Cutzamala: Agua para millones de mexicanos*. Comisión Nacional del Agua y Gerencia Regional de Aguas del Valle de México y Sistema Cutzamala.
- Estrada, F., & Guerrero, V. (2013). A cautionary note on automated statistical downscaling methods for climate change. *Climate Change, Springer*, 120(1), 263, 276.
- Guerrero, V. (1993). Time-series analysis supported by power transformations. *Journal of Forecasting*, 12(1), 37, 49.
- Hernández H., E. (2022). *Análisis de Disponibilidad Hídrica en el Sistema Cutzamala* (Tesis de Maestría). Universidad Nacional Autónoma de México.
- Huang, C., & Pethukina, A. (2022). *Applied Time Series and Forecasting with Python* (1st). Springer.
- IMTA. (2022). *Introducción a la seguridad hídrica*. Instituto Mexicano de Tecnología del Agua.
- IPCC. (2021). *Resumen técnico de las contribuciones del Grupo de Trabajo 1 al Sexto Reporte de Evaluación del IPCC*. Panel Intergubernamental del Cambio Climático.
- Juan D., E. (2021). *Políticas de operación con y sin curvas guías optimizadas para las principales presas del Sistema Cutzamala. Aplicación de programación evolutiva*. (Tesis de Maestría). Universidad Nacional Autónoma de México.
- Romero G., J. A. (2021). *Aplicación de Redes Neuronales Artificiales para la Predicción de Escurrecimientos en el Sistema Cutzamala* (Tesis de Maestría). Universidad Nacional Autónoma de México.
- Salas, J. D. e. a. (1980). *Applied Modeling of Time Series in Hydrology* (1st). Water Resources Publications.
- Tsay, R. S. (2005). *Analysis of Financial Time Series* (2nd). Wiley.
- WRI. (2021). *Assessing physical climate risks for the European Bank for Reconstruction and Development's power generation project investment portfolio*. Instituto de Recursos Mundiales.